

Report 8 – Diagnostica QALS

14 luglio 2026

1 Diagnostica di QALS

Fino ad ora i test su QALS sono stati svolti principalmente con l'obiettivo di verificare se, al variare delle configurazioni dei parametri, l'algoritmo fosse in grado di trovare soluzioni buone per il problema considerato. In particolare, l'interesse era quello di capire se QALS riuscisse a produrre soluzioni non troppo distanti da quella ottima. Tuttavia, per i test case di dimensione maggiore, i risultati ottenuti non sono stati sempre soddisfacenti. Per questo motivo si è deciso di introdurre una forma di diagnostica aggiuntiva, con lo scopo di osservare più nel dettaglio il comportamento dell'algoritmo durante la fase di ricerca.

L'idea consiste nell'utilizzare la distanza di Hamming tra configurazioni binarie. Nel contesto del problema Knapsack, una soluzione è rappresentata da un vettore binario:

$$z = (z_1, z_2, \dots, z_n),$$

dove:

$$z_i = \begin{cases} 1 & \text{se l'item } i \text{ è selezionato,} \\ 0 & \text{altrimenti.} \end{cases}$$

La distanza di Hamming tra due soluzioni binarie z e z' misura il numero di posizioni in cui esse differiscono:

$$d_H(z, z') = \sum_{i=1}^n \mathbf{1}_{z_i \neq z'_i}.$$

Nel nostro caso, questa misura permette di capire quanti item cambiano stato tra due soluzioni: un valore alto indica che molte variabili binarie sono diverse, mentre un valore basso indica che le due configurazioni sono simili.

2 Possibili confronti tramite distanza di Hamming

2.1 Distanza rispetto alla soluzione corrente accettata

I primi confronti consistono nel calcolare la distanza tra la soluzione candidata z_t e la soluzione corrente accettata dall'algoritmo, indicata con z_{star} :

$$d_H(z_t, z_{\text{star}}).$$

In questo caso z_{star} non deve essere interpretata come la soluzione ottima, ma come lo stato corrente dell'algoritmo. Infatti, QALS può accettare anche soluzioni peggiorative con una certa probabilità, al fine di evitare di bloccarsi prematuramente in minimi locali. Questa distanza misura l'ampiezza della mossa proposta nello spazio delle soluzioni. Rappresenta dunque una misura del movimento della ricerca rispetto alla configurazione attualmente accettata. Valori elevati indicano che l'algoritmo sta proponendo salti ampi nello spazio delle soluzioni, e quindi un comportamento più esplorativo. Valori bassi indicano invece che la nuova soluzione candidata è simile alla soluzione corrente, suggerendo una ricerca più locale attorno alla configurazione accettata.

Un'interpretazione simile si può adottare per:

$$d_H(z_t, z_{\text{opt}}).$$

2.2 Distanza rispetto soluzioni accettate consecutive

Nel terzo confronto si stima la distanza tra la soluzione accettata nell'iterazione precedente z_{starOld} e la soluzione corrente accettata dall'algoritmo, indicata con z_{starNew} :

$$d_H(z_{\text{starOld}}, z_{\text{starNew}}).$$

Come prima z_{starNew} non deve essere interpretata come la soluzione ottima, ma solo come lo stato corrente dell'algoritmo. Questa distanza misura quanto la nuova soluzione accettata da QALS si discosti da quella precedente. z_{star} può essere interpretato come la posizione di QALS e ad ogni nuova soluzione proposta si confronta con la nuova soluzione accettata.

2.3 Distanza fra soluzione ottima e soluzione accettata

Ed infine come ultima distanza si è presa in considerazione:

$$d_H(z_{\text{opt}}, z_{\text{star}}).$$

L'obiettivo di questa misurazione è quello di stimare quanto la soluzione correntemente accettata da QALS si distanzi dalla soluzione ottima.

3 Interpretazione generale

- $d_H(z_t, z_{\text{star}})$ misura l'ampiezza della mossa proposta rispetto alla soluzione corrente accettata;
- $d_H(z_t, z_{\text{opt}})$, similmente alla precedente, misura l'ampiezza della soluzione proposta rispetto alla soluzione ottima;
- $d_H(z_{\text{starOld}}, z_{\text{starNew}})$ permette di misurare la variazione delle soluzioni accettate
- $d_H(z_{\text{opt}}, z_{\text{star}})$ ci permette di capire quanto la soluzione accettata si distanzi da quella ottima.

4 Clustering

L'idea principale è raggruppare soluzioni simili tra loro. Poiché nel problema QUBO le soluzioni sono rappresentate come vettori binari, una misura naturale di distanza è la distanza di Hamming. In questo modo è possibile costruire una matrice delle distanze tra tutte le soluzioni generate da QALS. Tale matrice viene poi utilizzata come input per un algoritmo di clustering agglomerativo.

4.1 Procedura utilizzata

La procedura segue quattro passaggi principali. Prima si raccolgono tutte le soluzioni z generate durante l'esecuzione di QALS. Successivamente, per ogni coppia di soluzioni, viene calcolata la distanza di Hamming. I valori ottenuti vengono inseriti in una matrice simmetrica D , dove l'elemento $D[i][j]$ rappresenta la distanza tra la soluzione z_i e la soluzione z_j .

Una volta ottenuta la matrice delle distanze, viene applicato un algoritmo di clustering agglomerativo. Il clustering prevede di identificare dei cluster basandosi sulla distanza fra soluzioni, in particolare è stato impostato per far in modo che le soluzioni di un cluster abbiano al più una distanza media di hamming del 40%. L'algoritmo assegna quindi ogni soluzione a

uno dei cluster individuati. Infine, una volta calcolato il numero di soluzioni appartenenti a ciascun cluster si considera solo il cluster con cardinalità maggiore da cui si estrae il medoid. Il medoid è la soluzione appartenente al cluster che minimizza la distanza media di Hamming rispetto a tutte le altre soluzioni dello stesso cluster:

$$z_{\text{medoid}} = \arg \min_{z \in C_i} \frac{1}{|C_i| - 1} \sum_{\substack{z_j \in C_i \\ z_j \neq z}} d_H(z, z_j)$$

Conclusa la procedura si otterranno due vettori: il primo è il vettore *labels*, che associa ogni soluzione al cluster corrispondente; il secondo è *cluster_sizes*, che indica quante soluzioni appartengono a ciascun cluster.

Per esempio, se si ottiene:

$$labels = [0, 0, 1, 1, 1, 2]$$

allora le prime due soluzioni appartengono al cluster 0, le successive tre al cluster 1 e l'ultima al cluster 2. Di conseguenza, le dimensioni dei cluster sono:

$$cluster_sizes = \{0 : 2, 1 : 3, 2 : 1\}$$

Questa analisi permette di capire se QALS tende a generare soluzioni appartenenti a una sola regione dello spazio di ricerca oppure se esplora regioni differenti ed inoltre capire su quali soluzioni si concentra la ricerca. Un numero ridotto di cluster molto popolati può indicare una concentrazione della ricerca in poche zone, mentre molti cluster piccoli possono suggerire una maggiore dispersione delle soluzioni generate.

5 Risultati

In questa sezione vengono analizzati i risultati ottenuti sui file di test *ksp_1*, *ksp_3*, *ksp_2* e con:

$$\lambda_1 = \frac{\sum_{i=1}^n p_i}{650 \cdot C}, \quad \lambda_2 = \frac{\sum_{i=1}^n p_i}{3}.$$

In tutti i casi è stata utilizzata la seguente configurazione di QALS:

$$TIMES = 1, \quad k = 2000, \quad i_{\max} = 250, \quad N_{\max} = 125, \quad d_{\min} = 88.$$


5.1 ksp_1

Metrica	λ_1	λ_2
Numero cluster	9	8
Dimensione cluster massimo	224	136
Medoid cluster massimo	[0 1 1 1 1 1 1 1 1]	[1 1 0 1 0 0 1 1 1]
f_Q medoid	503.29	5139129.0
Profit medoid	347	295
Weight medoid	476	316
f_Q Min Found QALS	-306.32	-1404079.0
Profit Found QALS	261	239
Weight Found QALS	158	120
f_Q Min Found NO QALS	-330.85	-1455540.67
Profit Found NO QALS	302	198
Weight Found NO QALS	177	101


Tabella 1: Confronto dei risultati ottenuti con QALS e senza QALS.




(a) $d_H(z_\star^{old}, z_\star^{new})$ con λ_1




(b) $d_H(z_t, z_\star)$ con λ_1




(c) $d_H(z_{opt}, z_\star)$ con λ_1



(d) $d_H(z_{opt}, z_t)$ con λ_1



(e) $f_Q(z_\star)$ con λ_1



(f) $f_Q(z_t)$ con λ_1







Figura 2: Agglomerative Clustering Dendrogram




(a) $d_H(z_\star^{old}, z_\star^{new})$ con λ_2




(b) $d_H(z_t, z_\star)$ con λ_2




(c) $d_H(z_{opt}, z_\star)$ con λ_2



(d) $d_H(z_{opt}, z_t)$ con λ_2



(e) $f_Q(z_\star)$ con λ_2



(f) $f_Q(z_t)$ con λ_2





Figura 4: Agglomerative Clustering Dendrogram


5.2 ksp_3

Metrica	λ_1	λ_2
Numero cluster	37	32
Dimensione cluster massimo	79	100
Medoid cluster massimo	[000101111101011] [1001111000010101]	[001000111110111] [001101010001110]
f_Q medoid	320829.96	50443988075.67
Profit medoid	4272	3812
Weight medoid	4058	4741
f_Q Min Found QALS	54570.94	12624011894.67
Profit Found QALS	3467	2868
Weight Found QALS	2071	2666
f_Q Min Found NO QALS	-9424.80	-714267662.00
Profit Found NO QALS	2936	2483
Weight Found NO QALS	560	501


Tabella 2: Confronto dei risultati ottenuti con QALS e senza QALS.




(a) $d_H(z_{\star}^{old}, z_{\star}^{new})$ con λ_1




(b) $d_H(z_t, z_{\star})$ con λ_1




(c) $d_H(z_{opt}, z_{\star})$ con λ_1



(d) $d_H(z_{opt}, z_t)$ con λ_1



(e) $f_Q(z_{\star})$ con λ_1



(f) $f_Q(z_t)$ con λ_1







Figura 6: Agglomerative Clustering Dendrogram




(a) $d_H(z_{\star}^{old}, z_{\star}^{new})$ con λ_2




(b) $d_H(z_t, z_{\star})$ con λ_2




(c) $d_H(z_{opt}, z_{\star})$ con λ_2



(d) $d_H(z_{opt}, z_t)$ con λ_2



(e) $f_Q(z_{\star})$ con λ_2



(f) $f_Q(z_t)$ con λ_2





Figura 8: Agglomerative Clustering Dendrogram


5.3 ksp_2

Metrica	λ_1	λ_2
Numero cluster	49	43
Dimensione cluster massimo	108	77
f_Q medoid	8722714.33	1705778847401.0
Profit medoid	18423	16535
Weight medoid	14684	13984
f_Q Min Found QALS	2074250.86	511262925924.0
Profit Found QALS	14850	10932
Weight Found QALS	7747	8158
f_Q Min Found NO QALS	-54748.31	-10200709849.33
Profit Found NO QALS	7740	5669
Weight Found NO QALS	978	1001


Tabella 3: Confronto dei risultati ottenuti con QALS e senza QALS.




(a) $d_H(z_\star^{old}, z_\star^{new})$ con λ_1




(b) $d_H(z_t, z_\star)$ con λ_1




(c) $d_H(z_{opt}, z_\star)$ con λ_1



(d) $d_H(z_{opt}, z_t)$ con λ_1



(e) $f_Q(z_\star)$ con λ_1



(f) $f_Q(z_t)$ con λ_1







Figura 10: Agglomerative Clustering Dendrogram




(a) $d_H(z_\star^{old}, z_\star^{new})$ con λ_2




(b) $d_H(z_t, z_\star)$ con λ_2




(c) $d_H(z_{opt}, z_\star)$ con λ_2



(d) $d_H(z_{opt}, z_t)$ con λ_2



(e) $f_Q(z_\star)$ con λ_2



(f) $f_Q(z_t)$ con λ_2




Figura 12: Agglomerative Clustering Dendrogram

5.4 Interpretazione dei risultati

I risultati mostrano che QALS mantiene una certa capacità di generare configurazioni differenti, ma tale esplorazione non si traduce necessariamente in un miglioramento della soluzione corrente o nell'avvicinamento alla soluzione ottima.

In tutti e tre i test case, la distanza:

$$d_H(z_{\star}^{old}, z_{\star}^{new})$$

assume valori diversi da zero soprattutto nelle prime iterazioni, per poi diventare quasi sempre nulla. Questo comportamento indica che QALS modifica la soluzione corrente soprattutto nella fase iniziale dell'esplorazione, ma successivamente tende a mantenere la stessa configurazione per intervalli molto lunghi, ma ciò dipende dal parametro che decide la probabilità di accettare una nuova soluzione. I picchi isolati osservabili in alcune esecuzioni corrispondono all'accettazione occasionale di una nuova soluzione, eventualmente anche peggiorativa, prevista dal meccanismo probabilistico dell'algoritmo. Inoltre se considerassimo:

$$d_H(z_{opt}, z_{\star}) \quad f_Q(z_{\star})$$

si nota che $z_{\star}$ continui a diminuire ad ogni cambio.

Se ora prendessimo in considerazione le distanze:

$$d_H(z_t, z_{\star})$$

in tutti i casi si può vedere come tutte suggeriscano un'esplorazione variegata dello spazio delle soluzioni in quanto, in relazione ad ogni test case, le distanze oscillano in modo significativo mantenendo un valore superiore alla metà del numero di elementi per ogni test case.

In particolar nel test case **ksp_3** si noti come mano a mano che l'esecuzione procede, la distanza diminuisca, o per lo meno si appiattisca, pattern che però non si ripete né in **ksp_1** né in **ksp_2** il che può essere giustificato dal comportamento probabilistico dell'algoritmo.

Infine integrando con:

$$f_Q(z_t) \quad dendrogram$$

si può concludere che QALS abbia una certa capacità di esplorazione, ma che questa si concentri prevalentemente in alcune regioni dello spazio. Questo comportamento è meno evidente utilizzando $\lambda_2 = \frac{\sum_{i=1}^n p_i}{3}$.


Nel complesso, la diagnostica mostra quindi che QALS non è privo di esplorazione. Le soluzioni candidate continuano a variare e, soprattutto nei problemi di dimensione maggiore, risultano essere più distribuite tra cluster. Il problema principale non sembra essere l'assenza di movimento nello spazio delle soluzioni, bensì la scarsa efficacia della direzione seguita dalla ricerca. QALS esplora molte configurazioni, ma tende a concentrarsi nelle stesse regioni e distanti dall'ottimo; inoltre, dopo le prime iterazioni, modifica raramente la soluzione corrente.

6 Decay Factor


6.1 ksp_1

Metrica	λ_1	λ_2
Numero cluster	6	14
Dimensione cluster massimo	221	99
Medoid cluster massimo	[0010000000]	[1000001101]
f_Q medoid	-115.4	-1438289.0
Profit medoid	56	209
Weight medoid	68	112
f_Q Min Found QALS	-318.97	-1455268.0
Profit Found QALS	260	68
Weight Found QALS	135	102
f_Q Min Found NO QALS	-330.85	-1455540.67
Profit Found NO QALS	302	198
Weight Found NO QALS	177	101


Tabella 4: Confronto dei risultati ottenuti con QALS e senza QALS.




(a) $d_H(z_{\star}^{old}, z_{\star}^{new})$ con λ_1




(b) $d_H(z_t, z_{\star})$ con λ_1




(c) $d_H(z_{opt}, z_{\star})$ con λ_1



(d) $d_H(z_{opt}, z_t)$ con λ_1



(e) $f_Q(z_{\star})$ con λ_1



(f) $f_Q(z_t)$ con λ_1







Figura 14: Agglomerative Clustering Dendrogram




(a) $d_H(z_\star^{old}, z_\star^{new})$ con λ_2




(b) $d_H(z_t, z_\star)$ con λ_2




(c) $d_H(z_{opt}, z_\star)$ con λ_2



(d) $d_H(z_{opt}, z_t)$ con λ_2



(e) $f_Q(z_\star)$ con λ_2



(f) $f_Q(z_t)$ con λ_2





Figura 16: Agglomerative Clustering Dendrogram


6.2 ksp_3

Metrica	λ_1	λ_2
Numero cluster	37	27
Dimensione cluster massimo	88	111
Medoid cluster massimo	[0 1 0 1 0 1 0 1 0 0 0 1 1 1 1] [1 0 0 0 1 0 1 0 0 1 0 0 0 1 1]	[1 0 1 0 1 1 1 0 1 1 1 1 0 0 1] [1 0 1 1 0 0 0 0 1 0 0 1 0 1 0]
f_Q medoid	224789.03	48318846396.67
Profit medoid	4411	4470
Weight medoid	3500	4652
f_Q Min Found QALS	12282.1	10374371657.0
Profit Found QALS	2514	4168
Weight Found QALS	1404	2475
f_Q Min Found NO QALS	-9424.8	-714267360.0
Profit Found NO QALS	2936	2181
Weight Found NO QALS	560	501


Tabella 5: Confronto dei risultati ottenuti con QALS e senza QALS.




(a) $d_H(z_\star^{old}, z_\star^{new})$ con λ_1




(b) $d_H(z_t, z_\star)$ con λ_1




(c) $d_H(z_{opt}, z_\star)$ con λ_1



(d) $d_H(z_{opt}, z_t)$ con λ_1



(e) $f_Q(z_\star)$ con λ_1



(f) $f_Q(z_t)$ con λ_1







Figura 18: Agglomerative Clustering Dendrogram




(a) $d_H(z_{\star}^{old}, z_{\star}^{new})$ con λ_2




(b) $d_H(z_t, z_{\star})$ con λ_2




(c) $d_H(z_{opt}, z_{\star})$ con λ_2



(d) $d_H(z_{opt}, z_t)$ con λ_2



(e) $f_Q(z_{\star})$ con λ_2



(f) $f_Q(z_t)$ con λ_2





Figura 20: Agglomerative Clustering Dendrogram


6.3 ksp_2

Metrica	λ_1	λ_2
Numero cluster	45	46
Dimensione cluster massimo	43	80
f_Q medoid	859908.48	1458700681384.67
Profit medoid	12573	16403
Weight medoid	5427	13013
f_Q Min Found QALS	739961.93	566573490515.67
Profit Found QALS	11705	11767
Weight Found QALS	5126	8528
f_Q Min Found NO QALS	-54748.31	-10200710054.33
Profit Found NO QALS	7740	5874
Weight Found NO QALS	978	1001


Tabella 6: Confronto dei risultati ottenuti con QALS e senza QALS.




(a) $d_H(z_*^{old}, z_*^{new})$ con λ_1




(b) $d_H(z_t, z_*)$ con λ_1




(c) $d_H(z_{opt}, z_*)$ con λ_1



(d) $d_H(z_{opt}, z_t)$ con λ_1



(e) $f_Q(z_*)$ con λ_1



(f) $f_Q(z_t)$ con λ_1







Figura 22: Agglomerative Clustering Dendrogram




(a) $d_H(z_\star^{old}, z_\star^{new})$ con λ_2




(b) $d_H(z_t, z_\star)$ con λ_2




(c) $d_H(z_{opt}, z_\star)$ con λ_2



(d) $d_H(z_{opt}, z_t)$ con λ_2



(e) $f_Q(z_\star)$ con λ_2



(f) $f_Q(z_t)$ con λ_2




Figura 24: Agglomerative Clustering Dendrogram

6.4 Interpretazione dei risultati con Decay Factor

L' introduzione del decay factor nella matrice tabù ha lo scopo di ridurre progressivamente il contributo delle penalizzazioni associate alle soluzioni visitate nelle iterazioni precedenti. In questo modo, le informazioni più recenti mantengono un peso maggiore, mentre quelle più vecchie vengono gradualmente dimenticate. L' obiettivo è evitare che l' accumulo delle penalizzazioni nella matrice S condizioni eccessivamente la ricerca nelle fasi avanzate dell' algoritmo.

L' interpretazione di:

$$d_H(z_{\text{starOld}}, z_{\text{starNew}}) \quad d_H(z_{\text{opt}}, z_{\text{star}}) \quad f_Q(z_{\text{star}})$$

rimane la medesima. z_{opt} cambia raramente ma sempre a diminuire. Ad accezione del test case `ksp_2` con λ_1 che presenta un numero di cambiamenti maggiore rispetto agli altri test case.

Sono simili anche i risultati di:

$$d_H(z_t, z_{\text{star}}) \quad d_H(z_{\text{opt}}, z_t) \quad \text{NumeroCluster}.$$

Cambiano però:

- dimensioni dei cluster, risultano essere più omogenee il che permette di far pensare ad un' esplorazione migliore rispetto al non usare il decay factor;
- $f_Q(z_t)$ la quale tende a decrescere, specialmente nei casi in cui si utilizza λ_1 .