

Report 8 – Diagnostica QALS

11 luglio 2026

1 Diagnostica di QALS

Fino ad ora i test su QALS sono stati svolti principalmente con l'obiettivo di verificare se, al variare delle configurazioni dei parametri, l'algoritmo fosse in grado di trovare soluzioni buone per il problema considerato. In particolare, l'interesse era quello di capire se QALS riuscisse a produrre soluzioni non troppo distanti da quella ottima. Tuttavia, per i test case di dimensione maggiore, i risultati ottenuti non sono stati sempre soddisfacenti. Per questo motivo si è deciso di introdurre una forma di diagnostica aggiuntiva, con lo scopo di osservare più nel dettaglio il comportamento dell'algoritmo durante la fase di ricerca.

L'idea consiste nell'utilizzare la distanza di Hamming tra configurazioni binarie. Nel contesto del problema Knapsack, una soluzione è rappresentata da un vettore binario:

$$z = (z_1, z_2, \dots, z_n),$$

dove:

$$z_i = \begin{cases} 1 & \text{se l'item } i \text{ è selezionato,} \\ 0 & \text{altrimenti.} \end{cases}$$

La distanza di Hamming tra due soluzioni binarie z e z' misura il numero di posizioni in cui esse differiscono:

$$d_H(z, z') = \sum_{i=1}^n \mathbf{1}_{z_i \neq z'_i}.$$

Nel nostro caso, questa misura permette di capire quanti item cambiano stato tra due soluzioni: un valore alto indica che molte variabili binarie sono diverse, mentre un valore basso indica che le due configurazioni sono simili.

2 Possibili confronti tramite distanza di Hamming

2.1 Distanza rispetto alla soluzione corrente accettata

Il primo confronto consiste nel calcolare la distanza tra la soluzione candidata z_t e la soluzione corrente accettata dall'algoritmo, indicata con z_{star} :

$$d_H(z_t, z_{\text{star}}).$$

In questo caso z_{star} non deve essere interpretata come la soluzione ottima, ma come lo stato corrente dell'algoritmo. Infatti, QALS può accettare anche soluzioni peggiorative con una certa probabilità, al fine di evitare di bloccarsi prematuramente in minimi locali. Questa distanza misura l'ampiezza della mossa proposta nello spazio delle soluzioni. Rappresenta dunque una misura del movimento della ricerca rispetto alla configurazione attualmente accettata. Valori elevati indicano che l'algoritmo sta proponendo salti ampi nello spazio delle soluzioni, e quindi un comportamento più esplorativo. Valori bassi indicano invece che la nuova soluzione candidata è simile alla soluzione corrente, suggerendo una ricerca più locale attorno alla configurazione accettata.

2.2 Distanza rispetto soluzioni accettate consecutive

Nel secondo confronto si stima la distanza tra la soluzione accettata nell'iterazione precedente z_{starOld} e la soluzione corrente accettata dall'algoritmo, indicata con z_{starNew} :

$$d_H(z_{\text{starOld}}, z_{\text{starNew}}).$$

Come prima z_{starNew} non deve essere interpretata come la soluzione ottima, ma solo come lo stato corrente dell'algoritmo. Questa distanza misura quanto la nuova soluzione accettata da QALS si discosti da quella precedente. z_{star} può essere interpretato come la posizione di QALS e ad ogni nuova soluzione proposta si confronta con la nuova soluzione accettata.

3 Interpretazione generale

- $d_H(z_t, z_{\text{star}})$ misura l'ampiezza della mossa proposta rispetto alla soluzione corrente accettata;
- $d_H(z_{\text{starOld}}, z_{\text{starNew}})$ permette di misurare la variazione delle soluzioni accettate

4 Clustering

L'idea principale è raggruppare soluzioni simili tra loro. Poiché nel problema QUBO le soluzioni sono rappresentate come vettori binari, una misura naturale di distanza è la distanza di Hamming. In questo modo è possibile costruire una matrice delle distanze tra tutte le soluzioni generate da QALS. Tale matrice viene poi utilizzata come input per un algoritmo di clustering agglomerativo.

4.1 Procedura utilizzata

La procedura segue quattro passaggi principali. Prima si raccolgono tutte le soluzioni z generate durante l'esecuzione di QALS. Successivamente, per ogni coppia di soluzioni, viene calcolata la distanza di Hamming. I valori ottenuti vengono inseriti in una matrice simmetrica D , dove l'elemento $D[i][j]$ rappresenta la distanza tra la soluzione z_i e la soluzione z_j .

Una volta ottenuta la matrice delle distanze, viene applicato un algoritmo di clustering agglomerativo. Il clustering prevede di identificare dei cluster basandosi sulla distanza fra soluzioni, in particolare è stato impostato per far in modo che le soluzioni di un cluster abbiano al più una distanza media di hamming del 40%. L'algoritmo assegna quindi ogni soluzione a uno dei cluster individuati. Infine, una volta calcolato il numero di soluzioni appartenenti a ciascun cluster si considera solo il cluster con cardinalità maggiore da cui si estrae il medoid. Il medoid è la soluzione appartenente al cluster che minimizza la distanza media di Hamming rispetto a tutte le altre soluzioni dello stesso cluster:

$$z_{\text{medoid}} = \arg \min_{z \in C_i} \frac{1}{|C_i| - 1} \sum_{\substack{z_j \in C_i \\ z_j \neq z}} d_H(z, z_j)$$

Conclusa la procedura si otterranno due vettori: il primo è il vettore *labels*, che associa ogni soluzione al cluster corrispondente; il secondo è *cluster_sizes*, che indica quante soluzioni appartengono a ciascun cluster.

Per esempio, se si ottiene:

$$\text{labels} = [0, 0, 1, 1, 1, 2]$$

allora le prime due soluzioni appartengono al cluster 0, le successive tre al cluster 1 e l'ultima al cluster 2. Di conseguenza, le dimensioni dei cluster sono:

$$\text{cluster_sizes} = \{0 : 2, 1 : 3, 2 : 1\}$$

Questa analisi permette di capire se QALS tende a generare soluzioni appartenenti a una sola regione dello spazio di ricerca oppure se esplora regioni differenti ed inoltre capire su quali soluzioni si concentra la ricerca. Un numero ridotto di cluster molto popolati può indicare una concentrazione della ricerca in poche zone, mentre molti cluster piccoli possono suggerire una maggiore dispersione delle soluzioni generate.

5 Risultati

In questa sezione vengono analizzati i risultati ottenuti sui file di test `ksp_1`, `ksp_3`, `ksp_2` e con:

$$\lambda_1 = \frac{\sum_{i=1}^n p_i}{650 \cdot C}, \quad \lambda_2 = \frac{\sum_{i=1}^n p_i}{3}.$$


In tutti i casi è stata utilizzata la seguente configurazione di QALS:

$$TIMES = 1, \quad k = 2000, \quad i_{\max} = 250, \quad N_{\max} = 125, \quad d_{\min} = 88.$$


5.1 ksp_1

Metrica	λ_1	λ_2
Numero cluster	9	8
Dimensione cluster massimo	224	136
Medoid cluster massimo	[0 1 1 1 1 1 1 1 1]	[1 1 0 1 0 0 1 1 1]
f_Q medoid	503.29	5139129.0
Profit medoid	347	295
Weight medoid	476	316
f_Q Min Found QALS	-306.32	-1404079.0
Profit Found QALS	261	239
Weight Found QALS	158	120
f_Q Min Found NO QALS	-330.85	-1455540.67
Profit Found NO QALS	302	198
Weight Found NO QALS	177	101


Tabella 1: Confronto dei risultati ottenuti con QALS e senza QALS.




(a) $d_H(z_{\star}^{old}, z_{\star}^{new})$ con λ_1




(b) $d_H(z_t, z_{\star})$ con λ_1




(c) $d_H(z_{opt}, z_{\star})$ con λ_1



(d) $d_H(z_{opt}, z_t)$ con λ_1



(e) $f_Q(z_{\star})$ con λ_1



(f) $f_Q(z_t)$ con λ_1







Figura 2: Agglomerative Clustering Dendrogram




(a) $d_H(z_{\star}^{old}, z_{\star}^{new})$ con λ_2




(b) $d_H(z_t, z_{\star})$ con λ_2




(c) $d_H(z_{opt}, z_{\star})$ con λ_2



(d) $d_H(z_{opt}, z_t)$ con λ_2



(e) $f_Q(z_{\star})$ con λ_2



(f) $f_Q(z_t)$ con λ_2





Figura 4: Agglomerative Clustering Dendrogram


5.2 ksp_3

Metrica	λ_1	λ_2
Numero cluster	37	32
Dimensione cluster massimo	79	100
Medoid cluster massimo	[000101111101011] [1001111000010101]	[001000111110111] [001101010001110]
f_Q medoid	320829.96	50443988075.67
Profit medoid	4272	3812
Weight medoid	4058	4741
f_Q Min Found QALS	54570.94	12624011894.67
Profit Found QALS	3467	2868
Weight Found QALS	2071	2666
f_Q Min Found NO QALS	-9424.80	-714267662.00
Profit Found NO QALS	2936	2483
Weight Found NO QALS	560	501


Tabella 2: Confronto dei risultati ottenuti con QALS e senza QALS.




(a) $d_H(z_{\star}^{old}, z_{\star}^{new})$ con λ_1




(b) $d_H(z_t, z_{\star})$ con λ_1




(c) $d_H(z_{opt}, z_{\star})$ con λ_1



(d) $d_H(z_{opt}, z_t)$ con λ_1



(e) $f_Q(z_{\star})$ con λ_1



(f) $f_Q(z_t)$ con λ_1







Figura 6: Agglomerative Clustering Dendrogram




(a) $d_H(z_{\star}^{old}, z_{\star}^{new})$ con λ_2




(b) $d_H(z_t, z_{\star})$ con λ_2




(c) $d_H(z_{opt}, z_{\star})$ con λ_2



(d) $d_H(z_{opt}, z_t)$ con λ_2



(e) $f_Q(z_{\star})$ con λ_2



(f) $f_Q(z_t)$ con λ_2





Figura 8: Agglomerative Clustering Dendrogram


5.3 ksp_2

Metrica	λ_1	λ_2
Numero cluster	49	43
Dimensione cluster massimo	108	77
f_Q medoid	8722714.33	1705778847401.0
Profit medoid	18423	16535
Weight medoid	14684	13984
f_Q Min Found QALS	2074250.86	511262925924.0
Profit Found QALS	14850	10932
Weight Found QALS	7747	8158
f_Q Min Found NO QALS	-54748.31	-10200709849.33
Profit Found NO QALS	7740	5669
Weight Found NO QALS	978	1001


Tabella 3: Confronto dei risultati ottenuti con QALS e senza QALS.




(a) $d_H(z_\star^{old}, z_\star^{new})$ con λ_1




(b) $d_H(z_t, z_\star)$ con λ_1




(c) $d_H(z_{opt}, z_\star)$ con λ_1



(d) $d_H(z_{opt}, z_t)$ con λ_1



(e) $f_Q(z_\star)$ con λ_1



(f) $f_Q(z_t)$ con λ_1







Figura 10: Agglomerative Clustering Dendrogram




(a) $d_H(z_\star^{old}, z_\star^{new})$ con λ_2




(b) $d_H(z_t, z_\star)$ con λ_2




(c) $d_H(z_{opt}, z_\star)$ con λ_2



(d) $d_H(z_{opt}, z_t)$ con λ_2



(e) $f_Q(z_\star)$ con λ_2



(f) $f_Q(z_t)$ con λ_2




Figura 12: Agglomerative Clustering Dendogram

5.4 Interpretazione risultati

Si può vedere come in tutti i casi la soluzione accettata non cambi spesso nonostante la ricerca sia vasta in quanto dai grafici $d_H(z_t, z_*)$ si può notare come la distanza di Hamming oscilli molto il che rende evidente il comportamento esplorativo di QALS. Integrando queste informazioni con i risultati del clustering si può concludere che seppur la ricerca di QALS offre nuove soluzioni per la maggior parte dei casi queste appartengano ad un cluster ben specifico facendo notare come QALS ritorna spesso su soluzioni simili fra loro. Tale comportamento è più evidente nella versione con soft constraints.

Si noti inoltre come cambiando la dimensione del problema il numero di cluster aumenti e il la dimensione del cluster massimo dimuisca il che coincide con quello che ci si aspetta: più il problema diventa grande, più configurazioni ci possono essere e quindi più cluster possono essere individuati il che pilota la dimensione del cluster massimo a diminuire.

6 Decay Factor